
MINI PROJET — MACHINE LEARNING

Gestion du déséquilibre de classes pour l'analyse de sentiments en dialecte Algérien

*Master 1 DS & NLP — Semestre 2 Module : Machine Learning
Enseignante : Dr. Soraya Cheriguene
Année universitaire : 2025–2026*

Réalisé par : Aissat Mohamed Moncef

Contents

1.	Introduction et Problématique	3
2.	État de l'Art	4
2.1	Déséquilibre de classes en apprentissage automatique	4
2.2	TALN pour le dialecte algérien	4
2.3	Stratégies de rééquilibrage en NLP	4
3.	Présentation du Corpus TWIFL et Analyse Exploratoire	5
3.1	Description du corpus	5
3.2	Analyse de la variable cible	5
3.3	Analyse linguistique des tweets	5
3.4	Prétraitement adapté au darija	7
4.	Méthodologie	9
4.1	Protocole expérimental	9
4.2	Modèle Baseline	9
4.3	Stratégie 1 — Modification de la fonction de perte	9
4.4	Stratégie 2 — Rééquilibrage dans l'espace des embeddings	10
4.5	Stratégie 3 — Back-Translation	10
5.	Résultats	11
5.1	Tableau comparatif global	11
5.2	Matrices de confusion — Sélection	12
5.2.1	Modèle Baseline	12
5.2.2	SMOTE	13
5.2.3	Adasyn	14
5.3	Courbes Précision-Rappel	15
6.	Discussion	17
6.1	Analyse Critique	17
6.2	Spécificités du darija algérien : une source de défis persistants	20
7	Conclusion et Perspectives	21
9	Références Bibliographiques	22

1. Introduction et Problématique

L'essor des réseaux sociaux a généré une quantité massive de données textuelles en langues peu dotées, parmi lesquelles le dialecte algérien — la *darja* — occupe une place particulière. Parlée au quotidien par près de 44 millions d'Algériens, cette langue reste profondément sous-représentée dans les ressources numériques et les corpus annotés. L'analyse de sentiments en darja constitue pourtant un enjeu stratégique pour des applications aussi diverses que la veille médiatique, la détection de discours haineux, ou l'analyse d'opinion politique.

Au coeur des défis propres à ce domaine se trouve le **déséquilibre de classes** : dans les corpus réels, certains sentiments — typiquement les opinions neutres ou négatives — sont beaucoup moins fréquents que les sentiments positifs. Ce phénomène biaise systématiquement les modèles d'apprentissage automatique, qui apprennent à optimiser une métrique globale (l'accuracy) en sacrifiant la performance sur les classes minoritaires, pourtant souvent les plus informatives.

Ce projet s'inscrit dans cette problématique en proposant une exploration comparative de trois familles de stratégies de rééquilibrage : (1) la modification de la fonction de perte, (2) le rééquilibrage dans l'espace des embeddings, et (3) l'augmentation de données par back-translation. Toutes ces stratégies sont évaluées sur le corpus **TWIFL** en utilisant **DziriBERT** comme modèle Transformer de référence, spécifiquement pré-entraîné sur le dialecte algérien.



2. État de l'Art

2.1 Déséquilibre de classes en apprentissage automatique

Le déséquilibre de classes est un problème fondamental en apprentissage automatique, documenté dès les années 1990. Chawla et al. [1] ont introduit SMOTE en 2002, proposant pour la première fois une sur-échantillonnage synthétique plutôt qu'une simple duplication. He et al. [2] ont ensuite proposé ADASYN, qui adapte la densité de génération à la difficulté locale de chaque exemple.

Du côté des approches algorithmiques, Lin et al. [3] ont introduit la Focal Loss, initialement conçue pour la détection d'objets en vision par ordinateur, mais dont l'efficacité a été démontrée sur des tâches NLP déséquilibrées. Cette perte réduit dynamiquement la contribution des exemples faciles, forçant le modèle à se concentrer sur les exemples difficiles et les classes minoritaires.

Les approches hybrides combinant modification de perte et rééquilibrage des données montrent des gains supplémentaires [4]. L'utilisation d'embeddings pré-entraînés comme espace de synthèse (SMOTE sur embeddings BERT) a été proposée par Schwartz et al. [5], contournant le problème de génération de texte brut cohérent.

2.2 TALN pour le dialecte algérien

Le dialecte algérien présente des caractéristiques linguistiques qui complexifient le TALN : (i) l'**Arabizi**, écriture translittérée en caractères latins avec chiffres (ex. *w9t* pour وقت), (ii) le **code-switching** arabe-français fréquent, (iii) l'absence de standardisation orthographique, et (iv) la richesse morphologique de l'arabe dialectal.

Boujou et al. [6] ont publié le corpus **TWIFL**, premier corpus algérien annoté pour l'opinion et l'émotion à grande échelle. Parallèlement, Abdaoui et al. [7] ont développé **DziriBERT**, un modèle BERT pré-entraîné sur 20 millions de tokens en dialecte algérien, offrant une tokenisation adaptée au darija et à l'Arabizi. Ces deux ressources constituent l'état de l'art pour les tâches de classification de sentiments en algérien.

Les travaux antérieurs sur le dialecte arabe maghrébin montrent que les modèles multilingues comme mBERT ou XLM-R sont systématiquement surpassés par DziriBERT sur des tâches spécifiques au dialecte algérien, notamment en raison d'une meilleure représentation du vocabulaire Arabizi [7].

2.3 Stratégies de rééquilibrage en NLP

Trois grandes familles de méthodes ont été appliquées au NLP pour gérer le déséquilibre de classes :

- **Méthodes au niveau des données** : sur-échantillonnage (SMOTE, ADASYN, duplication), sous-échantillonnage (Random Under-sampling, Tomek Links), ou combinaison des deux.
- **Méthodes au niveau de l'algorithme** : modification de la fonction de perte (class weighting, Focal Loss, Label-Smoothing adaptatif), modification du seuil de décision.
- **Méthodes d'augmentation de données** : back-translation, paraphrase par modèle de langage, remplacement de synonymes, insertion et suppression aléatoires (EDA de Wei & Zou [8]).

Dans le contexte spécifique du dialecte algérien, la back-translation présente des défis supplémentaires liés à la rareté des modèles de traduction de qualité pour le darija. Les modèles disponibles (Helsinki-NLP) ont principalement été entraînés sur l'arabe standard, induisant une dérive stylistique lors de la retraduction.

3. Présentation du Corpus TWIFL et Analyse Exploratoire

3.1 Description du corpus



Le corpus **TWIFL** (Algerian Corpus and Annotation Platform for Opinion and Emotion Analysis) est disponible librement sur HuggingFace sous la référence *arbml/Twifil*. Il contient **6 000 tweets** collectés sur Twitter, rédigés en dialecte algérien (arabe dialectal, Arabizi, code-switching arabe-français) et annotés manuellement par des locuteurs natifs pour la polarité de sentiment (Positif / Négatif / Neutre).

3.2 Analyse de la variable cible

La distribution des classes dans le corpus révèle un déséquilibre modéré avec la classe Positive largement majoritaire :

Classe	Nb exemples	% corpus	Moy. mots	Moy. caractères
Positive	2 864	47,7 %	9,89	71,86
Negative	1 773	29,5 %	13,49	89,97
Neutral	1 363	22,7 %	5,68	56,34
TOTAL	6 000	100 %	9,99	73,69


Tableau 1 — Distribution des classes dans le corpus TWIFL

Le **ratio de déséquilibre** étant égal a : **2.10** indique un déséquilibre **modéré**. La classe Neutre est la plus difficile à détecter en raison de sa faible représentation et de son ambiguïté sémantique (tweets factuels, ironie, sarcasme).

3.3 Analyse linguistique des tweets

L'analyse des 6 000 tweets révèle les caractéristiques linguistiques suivantes :

- 41 % des tweets sont étiquetés comme arabes (ar), 20,7 % indéterminés (und), 18,5 % français, 12,2 % anglais.
- 38,3 % des tweets présentent du code-switching (présence simultanée de caractères arabes et latins).
- Environ 21.65% des tweets contiennent des emojis. La classe Positive présente la plus forte densité d'emojis positifs (😊, ❤️, 👍).
- Longueur : Les tweets Négatifs sont en moyenne les plus longs (13.49 mots), possiblement car l'expression d'une frustration nécessite plus de contexte. Les tweets Neutres sont les plus courts (8.2mots).




- Les nuages de mots par classe révèlent des patterns distincts : la classe Positive est dominée par des termes de louange (*رائع*, *بارك الله*, *mzyen*), la classe Négative par des termes de critique (*خايب*, *hchouma*, *mauvais*), et la classe Neutre par des marqueurs temporels et factuels.
- Analyse des tweets de langue indéterminée (und) :

	Classe	Nb exemples	% du corpus	Moy. mots	Moy. caracteres
0	Positive	227	65.8%	2.89	75.09
1	Negative	46	13.3%	3.98	81.24
2	Neutral	72	20.9%	4.51	44.79
3	TOTAL	345	100%	3.37	69.59

Les tweets étiquetés und (indéterminée) représentent 345 messages, soit 5,75 % du corpus nettoyé. Cette catégorie, que l'énoncé demandait de conserver, présente des caractéristiques particulières qui méritent d'être soulignées.

Une classe très fortement déséquilibrée. La distribution des sentiments est encore plus biaisée que celle du corpus global : la classe Positive concentre 65,8 % des tweets (227), suivie de Neutral (72 tweets, 20,9 %) et de Negative (46 tweets, 13,3 %). Le ratio de déséquilibre atteint 4,93 (Positive/Negative), soit un déséquilibre « fort » selon l'échelle adoptée.



Des tweets très courts et pauvres en contexte. La longueur moyenne des tweets und est de seulement 3,37 mots, contre 9,99 mots sur l'ensemble du corpus. La classe Positive est la plus brève (2,89 mots en moyenne), ce qui suggère que beaucoup de ces tweets sont des expressions simples (émoticônes, interjections, salutations) plutôt que des opinions développées. La Neutral se distingue par une moyenne de caractères étonnamment basse (44,79) malgré un nombre de mots plus élevé (4,51), probablement à cause de nombreux tokens très courts (prépositions, abréviations).

Absence d'emojis natifs et présence d'emojis convertis. La proportion de tweets contenant des emojis (*avant* conversion) est mesurée à 0,00 %. Ce chiffre s'explique par la méthode d'analyse : la détection a été effectuée après l'étape de *demojize* (conversion des emojis en texte), ce qui fait que plus aucun emoji natif n'est présent. Les nuages de mots montrent en revanche des formes textuelles d'emojis comme `sparkling_heart`, `clapping_hands` ou `face_with_tears_of_joy`, confirmant que de nombreux tweets und contenaient bien des emojis à l'origine. Ils constituent donc une part importante de l'expressivité émotionnelle de ces messages très courts.

Un code-switching limité. Seuls 14,49 % des tweets und mêlent caractères arabes et latins, contre 38,3 % dans le corpus global. Cette faible proportion indique que ces tweets sont majoritairement rédigés dans un seul système d'écriture (probablement soit entièrement en arabe, soit entièrement en caractères latins / Arabizi), avec peu d'alternance codique. Cela peut faciliter leur traitement par les modèles de traduction ou les tokenizers, mais cela les rend aussi moins représentatifs de la diversité linguistique du darija.

Des contenus disparates selon la polarité. Les nuages de mots révèlent des motifs différents par classe :



- **Positive** : emojis positifs (`sparkling_heart`, `clapping_hands`, `face_with_tears_of_joy`), confirmant une expression émotionnelle simple.
- **Negative** : termes d'emojis similaires mais avec des variantes (`sailing_face_with_tears_of_joy`, `sitting_faces`, `smiling_faces`), qui peuvent correspondre à des emplois ironiques ou à des réactions non-négatives labellisées à tort.
- **Neutral** : une grande hétérogénéité lexicale (`soccer_bal`, `photography`, noms propres, lieux, Algeria, Türkiye), suggérant que ces tweets sont des mentions factuelles, des retweets d'actualité ou des commentaires sans polarité marquée.

Conclusion sur les tweets und.

Ces tweets forment un sous-ensemble à la fois minoritaire et atypique : très courts, peu mélangés linguistiquement, dominés par des réactions positives sous forme d'emojis, et avec une classe Neutral dispersée thématiquement. Leur conservation dans le corpus est justifiée car ils représentent une fraction réelle des données. Leur impact sur l'apprentissage est toutefois ambivalent : leur brièveté et leur déséquilibre extrême risquent d'accentuer le biais en faveur de la classe Positive, tout en offrant peu de contexte discriminant pour la classe Neutral. Des précautions comme le filtrage des tweets < 2 mots permettent d'atténuer ces effets sans perdre l'information qu'ils contiennent.

3.4 Prétraitement adapté au darija

Un pipeline de prétraitement spécifique a été développé pour le dialecte algérien, s'écartant volontairement des pipelines génériques pour l'arabe standard :

- **Suppression** des URLs (*https://t.co/...*), mentions (*@utilisateur*), et doublons.
- **Normalisation des emojis** : les emojis ont été *convertis en tokens textuels* (ex. 😊 → :smile:)
Plutôt que supprimés, car ils portent une information sentimentale significative en darija. Cela représente un écart justifié par rapport aux pipelines standards.
- **Normalisation des répétitions** : les lettres répétées (« مزيان » → « مميزان ») ont été réduites à deux occurrences maximum.
- **Conversion des chiffres arabes orientaux** : en chiffres occidentaux. Justification :
 - **Tokenisation cohérente** – DziriBERT (comme la plupart des modèles BERT) a été pré-entraîné sur des textes où les chiffres sont majoritairement en forme occidentale. Les chiffres orientaux peuvent être découpés en sous-mots ou traités comme des tokens inconnus, ce qui nuit à la compréhension des valeurs numériques.
 - **Réduction de la variabilité orthographique** – Dans le darija, les deux formes coexistent (parfois dans le même tweet). Les ramener à une seule représentation évite que le modèle considère "123" et "١٢٣" comme deux entités différentes alors qu'ils ont le même sens.
 - **Amélioration de la représentation sémantique** – Les nombres (dates, quantités, heures) portent du sens. Une représentation stable permet au modèle de mieux capturer cette information, surtout quand le code-switching mélange chiffres arabes et latins.
- **Conservation du code-switching** : Proportion de tweets avec code-switching : 38,33 %, les mots français n'ont pas été supprimés, car ils constituent une caractéristique linguistique authentique du darija.
- **Tweets courts** (1-2 mots) : Suppression des tweets de moins de 2 mots. Justification :
 - **Manque de contexte sémantique** – Un tweet d'un ou deux mots (ex. « Merci », « Non », « Ok », « Bonjour ») ne fournit pas suffisamment d'indices lexicaux pour déterminer de manière fiable la polarité du sentiment. Même un modèle pré-entraîné comme DziriBERT s'appuie sur le contexte des mots et les relations syntaxiques ; un énoncé trop court réduit ces signaux, rendant la classification hasardeuse.
 - **Ambiguïté élevée** – Des mots isolés peuvent changer de polarité selon le contexte. Par exemple, le mot « سلام » (paix/salut) est employé aussi bien dans des contextes neutres que positifs, sans que le texte ne donne d'indices supplémentaires. Conserver ces tweets introduit du bruit sans apporter d'information réellement exploitable.
 - **Cohérence avec la tâche de classification** – L'analyse d'opinion porte sur des énoncés exprimant un jugement, une émotion ou une appréciation, qui nécessitent généralement un minimum d'élaboration linguistique. Les tweets très courts correspondent souvent à des réponses automatiques, des salutations ou des interjections qui ne contiennent pas de véritable opinion.
434 tweets ont été retirés, soit environ 9 % du corpus nettoyé.
- **Aucun stemming ni lemmatisation** : conformément aux recommandations, DziriBERT effectue sa propre tokenisation sous-lexicale.
- **Tweet de langue 'und'** : ont été préservés.

Après prétraitement, le corpus final compte **4 488 tweets valides**. (soit 1 078 tweets supprimés par rapport aux 6 000 initiaux – doublons, vides, sans contenu textuel)

4. Méthodologie

4.1 Protocole expérimental

Le protocole suivant a été appliqué strictement pour garantir la reproductibilité et la comparabilité des résultats :

- Partitionnement stratifié unique avec `random_state=42` : 70 % entraînement (3 141 tweets), 15 % validation (673 tweets), 15 % test (674 tweets).
- Le test set n'est jamais modifié, rééquilibré, ou ré-utilisé pour des choix de modèle.
- Hyperparamètres imposés : 5 epochs, `lr=2e-5`, `batch_size=16`, optimiseur AdamW, `seed=42`.
- Métriques principales : F1-macro, F1 par classe, AUC-PR, G-mean, matrice de confusion.
- L'accuracy est reportée uniquement à titre illustratif pour montrer son caractère trompeur.

4.2 Modèle Baseline

DziriBERT (alger-ia/dziribert) a été fine-tuné avec les hyperparamètres imposés (5 epochs, learning rate 2×10^{-5} , batch size 16, AdamW). Le modèle est entraîné sur le train set déséquilibré, sans aucune technique de rééquilibrage. Un early-stopping (patience=3) sur la métrique F1-macro empêche le sur-apprentissage.

Comme attendu, la baseline présente un biais marqué vers la classe Positive. Le F1 de la classe Neutre est particulièrement faible, le modèle ignorant largement cette classe minoritaire. Ce comportement constitue notre **référence à améliorer**.

4.3 Stratégie 1 — Modification de la fonction de perte

4.3.1— Class Weighting

Le poids de chaque classe est calculé selon la formule inverse à la fréquence :

$$w_k = N_{\text{total}} / (N_{\text{classes}} \times N_k)$$

Les poids obtenus sont : $w_{\text{Positif}} \approx 0.63$, $w_{\text{Négatif}} \approx 1.17$, $w_{\text{Neutre}} \approx 2.40$. Ces poids sont injectés dans la fonction `CrossEntropyLoss` de PyTorch. Tous les autres hyperparamètres restent identiques à la baseline.

4.3.2— Focal Loss

La Focal Loss, définie comme $FL(p_t) = -\alpha_t(1-p_t)^\gamma \cdot \log(p_t)$, réduit dynamiquement la contribution des exemples faciles. Nous testons $\gamma \in \{1, 2\}$ et évaluons également la combinaison Focal Loss + Class Weighting (variante C). L'implémentation suit Lin et al. [3], avec α_t correspondant aux poids de classe.— Combinaison Class Weighting + Focal Loss

4.3.3 — Combinaison Class Weighting + Focal Loss

La variante C applique simultanément les poids de classe ET le facteur focal. Les poids corrigent le déséquilibre structurel entre classes, tandis que la Focal Loss gère la difficulté des exemples individuels. Cette combinaison nécessite un calibrage plus fin du paramètre γ pour éviter une sur-pénalisation des exemples faciles.

4.4 Stratégie 2 — Rééquilibrage dans l'espace des embeddings

Cette stratégie intervient sur les données elles-mêmes, dans l'espace vectoriel de DziriBERT plutôt que sur le texte brut.

4.4.1— Extraction des embeddings [CLS]

DziriBERT est utilisé en mode feature extraction (sans gradient, couche de classification retirée). Pour chaque tweet du train set, le vecteur [CLS] de dimension 768 est extrait. La matrice résultante de forme (4 111, 768) constitue la représentation vectorielle du corpus d'entraînement.

4.4.2— SMOTE sur embeddings

SMOTE ($k=5$ voisins) est appliqué sur la matrice d'embeddings pour équilibrer les classes. Nous testons deux niveaux de rééquilibrage : équilibre total (toutes les classes à $n = 3\,127$) et rééquilibrage partiel ($n_{\text{Neutre}} = 1\,500$, $n_{\text{Négatif}} = 2\,000$). Un MLP (couches $768 \times 256 \times 128 \times 3$, ReLU, dropout=0.3) est entraîné sur les embeddings rééquilibrés.

4.4.3— ADASYN sur embeddings


ADASYN adapte la densité de génération à la difficulté locale : les exemples de la classe minoritaire entourés de nombreux exemples majoritaires reçoivent proportionnellement plus de voisins synthétiques. Le paramètre d'acceptance rate est fixé à $\alpha=1.0$ pour un rééquilibrage complet.

4.5 Stratégie 3 — Back-Translation

La back-translation génère des paraphrases naturelles en exploitant la traduction automatique comme étape intermédiaire. Le processus est appliqué *uniquement* aux tweets de la classe Neutre (la plus minoritaire) dans le train set.

- **Phase 1 — Sélection** : 575 tweets Neutres du train set sont sélectionnés.
- **Phase 2 — Traduction arabe $\rightarrow$ français** : modèle Helsinki-NLP/opus-mt-ar-fr.
 - **Phase 3 — Retraduction français $\rightarrow$ arabe** : modèle Helsinki-NLP/opus-mt-fr-ar.
- **Phase 4 — Filtrage par similarité cosinus** : seules les paraphrases avec similarité cosinus (embeddings DziriBERT) comprise entre 0.50 et 0.85 sont conservées.

Trois taux d'augmentation sont testés : +20 %, +50 %, +100 % de la taille originale de la classe Neutre. DziriBERT est ensuite re-fine-tuné sur le train set augmenté.



5. Résultats

5.1 Tableau comparatif global

Tous les modèles sont évalués sur le même test set figé (674 tweets). Les valeurs reportées sont les moyennes sur 3 runs avec différentes seeds.


Configuration	F1-macro	F1 Pos.	F1 Nég.	F1 Neutre	AUC-PR	G-mean
Baseline (données brutes)	0.6908	0.7983	0.7486	0.5254	0.7453	0.7539
Class Weighting	0.6782	0.7881	0.7537	0.4930	0.7288	0.7597
Focal Loss ($\gamma=1$)	0.6912	0.8000	0.7534	0.5203	0.7368	0.7569
Focal Loss ($\gamma=2$)	0.6937	0.8006	0.7569	0.5238	0.7292	0.7596
CW + Focal Loss ($\gamma=1$)	0.6660	0.7918	0.7437	0.4626	0.7183	0.7525
SMOTE + MLP (total)	0.6213	0.7442	0.6924	0.4274	0.6705	0.7048
SMOTE + MLP (partiel)	0.6306	0.7661	0.6948	0.4308	0.6638	0.7167
ADASYN + MLP	0.6204	0.7594	0.7081	0.3937	0.6517	0.7116
Back-Translation 20%	0.6935	0.8017	0.7556	0.5231	0.7557	0.6548
Back-Translation (+50%)	0.6727	0.7887	0.7333	0.4962	0.7295	0.6352
Back-Translation (+100%)	0.6989	0.8102	0.7485	0.5379	0.7412	0.6767

Tableau 2 — Comparaison des stratégies sur le test set (F1-macro, F1 par classe, AUC-PR, G-mean)



5.2 Matrices de confusion — Sélection

5.2.1 Modèle Baseline




Matrice de confusion du modèle Baseline

Analyse :

- Negative : 195/252 bien classés (rappel = 77,4 %). 56 tweets négatifs sont confondus avec Positif, presque aucun avec Neutre (1 seul).
- Neutral : seulement 31/77 bien prédits (rappel = 40,3 %). 21 sont classés Négatif, 25 Positif. La confusion est symétrique.
- Positive : 283/345 bien classés (rappel = 82,0 %). 53 sont prédits Négatif, 9 Neutre.

Ce qu'on en conclut : Le modèle distingue bien les classes extrêmes (Positive et Negative), mais la classe Neutral est très difficile à identifier. Elle est dispersée également entre Négatif et Positif. Le fort déséquilibre en faveur de la Positive n'est pas la seule cause : la Neutral semble intrinsèquement ambiguë. C'est le point de référence que les stratégies doivent améliorer.

5.2.2 SMOTE




Matrice de confusion - SMOTE Ratio 50%

Analyse :

- Negative : rappel = 74,6 % (baisse de 2,8 points par rapport à la baseline). Davantage de négatifs sont pris pour des Positifs (60 vs 56).
- Neutral : rappel = 32,5 % (baisse de 7,8 points !). Le modèle n'a donc pas mieux appris le Neutre ; il le confond toujours majoritairement avec Négatif et Positif.
- Positive : rappel = 74,2 % (baisse de 7,8 points). 78 Positifs sont classés Négatif, ce qui est plus que dans la baseline (53).

Ce qu'on en conclut : Ce rééquilibrage partiel a détérioré les performances sur toutes les classes par rapport à la baseline. Les exemples synthétiques générés par SMOTE semblent avoir brouillé les frontières de décision au lieu de les clarifier. Le F1-macro global tombe à 0,6213 (contre 0,6908 pour la baseline).

5.2.3 Adasyn



Matrice de confusion - ADASYN équilibre total

Analyse :

- Negative : rappel = 74,6 % (identique à SMOTE).
- Neutral : rappel = 32,5 % (identique à SMOTE).
- Positive : rappel = 75,9 % (meilleur que SMOTE mais toujours inférieur à la baseline).
-

Ce qu'on en conclut : ADASYN, qui a généré 1727 exemples synthétiques pour équilibrer totalement les classes, n'a pas réussi à améliorer la reconnaissance du Neutre. Pire : il a augmenté les confusions entre Négatif et Positif (67 Positifs classés Négatif, 55 Négatifs classés Positif). Le sur-échantillonnage massif a créé du bruit. Le F1-macro est le plus bas : 0,6204.

Synthèse comparative :


Ces trois matrices montrent que :

- La **Baseline** a déjà un bon niveau sur les classes Positive et Negative, mais le Neutral reste faible (rappel 40 %).
- Les méthodes de rééquilibrage par embeddings (**SMOTE** et **ADASYN**) n'apportent **aucun gain** sur le Neutral et dégradent même les performances globales.
- La classe Neutral est la plus problématique : elle est systématiquement confondue avec les autres, quelle que soit la stratégie. Cela suggère qu'elle est mal définie ou que les embeddings de DziriBERT ne capturent pas une séparation nette pour cette classe.

5.3 Courbes Précision-Rappel

Les courbes AUC-PR par classe confirment les tendances observées dans le tableau comparatif. La classe Neutre présente la plus forte progression en AUC-PR (+0.252 entre baseline et back-translation), tandis que la classe Positive connaît une légère baisse (-0.023), cohérente avec le transfert d'attention vers les classes minoritaires.

L'AUC-PR est préférée à l'AUC-ROC pour les données déséquilibrées car elle n'est pas influencée par le grand nombre de vrais négatifs, offrant une évaluation plus représentative de la capacité du modèle à détecter les classes minoritaires.



Interprétation / Explication des résultats AUC-PR

L'AUC-PR (Area Under the Precision-Recall curve – aire sous la courbe précision-rappel) est particulièrement informatif pour les problèmes de classification déséquilibrée, car il se concentre sur la performance relative à la classe positive (minoritaire). Une AUC-PR plus élevée signifie un meilleur compromis entre précision et rappel.

Observations clés :

- Back-Translation 20% atteint la meilleure AUC-PR (0,7557)**
C'est même supérieur à la baseline (0,7453). Une légère back-translation semble introduire des variations synthétiques utiles qui améliorent la capacité du modèle à distinguer la classe minoritaire sans dégrader le signal original.
- La baseline (données brutes) se classe deuxième (0,7453) – c'est une référence solide.**
Les données brutes donnent déjà une bonne performance en précision-rappel, ce qui indique que le déséquilibre de classe initial n'est peut-être pas très sévère ou que le MLP peut le gérer modérément bien.
- Back-Translation (+100%) (0,7412) et Back-Translation (+50%) (0,7295)**
À mesure que la quantité de back-translation augmente, l'AUC-PR diminue après le point optimal (20%). Trop de bruit synthétique dégrade probablement la qualité sémantique du texte, nuisant à l'équilibre précision-rappel.
- Class weighting (pondération des classes) (0,7288) et Focal Loss ($\gamma=1$: 0,7368 ; $\gamma=2$: 0,7292)**
Ces méthodes sensibles au coût performant légèrement en dessous de la baseline (sauf Focal Loss $\gamma=1$ qui est proche). Elles aident, mais ne surpassent pas la meilleure approche d'augmentation des données (Back-Translation 20%).

- Focal Loss avec $\gamma=1$ est équivalent à l'entropie croisée standard avec un facteur d'équilibrage ; sa valeur (0,7368) se situe entre la baseline et la pondération des classes.

5. **Combinaison CW + Focal Loss ($\gamma=2$) (0,7183)**

Combiner deux stratégies de re-pondération n'améliore pas la performance ; cela peut pénaliser excessivement la classe majoritaire et nuire à la précision.

6. **Rééchantillonnage avec MLP (SMOTE total/partiel, ADASYN) donne les AUC-PR les plus faibles (0,6517 – 0,6705)**

Ces méthodes de sur-échantillonnage, bien que couramment utilisées pour les données déséquilibrées, semblent introduire de nombreux échantillons synthétiques bruités ou peu représentatifs pour cet ensemble de données. En conséquence, la précision chute (plus de faux positifs) et l'AUC-PR en souffre considérablement.

Conclusion

- **Meilleure configuration** : Back-Translation 20% (AUC-PR = 0,7557)
- **Pires configurations** : ADASYN + MLP (0,6517) et les variantes SMOTE ($\leq 0,6705$)
- **Recommandation** : Pour cette tâche, une légère augmentation par back-translation est la plus bénéfique. Évitez le sur-échantillonnage lourd (SMOTE/ADASYN) car il dégrade la performance en précision-rappel.

6. Discussion

6.1 Analyse Critique

Stratégie 1 — Analyse de la modification de la fonction de perte

Q1 — Le F1 de la classe minoritaire a-t-il augmenté par rapport à la Baseline ?

- **Pour la classe Neutral :**

Non. Le F1-Neutral de la baseline est de 0.5254. Avec Class Weighting, il chute à 0.4930. Avec Focal Loss $\gamma=2$, il baisse légèrement à 0.5238. Aucune variante n'améliore significativement la classe minoritaire ; la meilleure la maintient quasiment à l'identique.

- **Pour la classe Négative :**

Oui. Le F1-Negative de la baseline est de 0.7486. Avec Focal Loss $\gamma=2$, il augmente à 0.7569.

Q2 — Y a-t-il un compromis ? Le F1 de la classe majoritaire a-t-il baissé ?

Non, au contraire. Il a augmenté très légèrement. Le F1-Positive de la baseline est de : **0.7983**, il augmente ensuite légèrement avec Focal Loss $\gamma=2$ pour arrive à la valeur : **0,8006**. La classe majoritaire n'est pas sacrifiée.

Q3 — Quel gamma donne les meilleurs résultats sur TWIFL ?

$\gamma=2$ est légèrement meilleur que $\gamma=1$ (F1-macro **0.6937** vs **0.6912**, F1-Neutral **0.5238** vs **0.5203**). La différence est minime, mais $\gamma=2$ force un peu plus le modèle à se concentrer sur les exemples difficiles.

Q4 — Class Weighting ou Focal Loss : quelle variante est la plus efficace ?

Focal Loss $\gamma=2$ est la meilleure de cette stratégie (F1-macro 0.6937), suivie de Focal Loss $\gamma=1$ (0.6912). Le Class Weighting seul dégrade les performances (0.6782). La combinaison CW+Focal est la plus mauvaise (0.6660). Conclusion : sur TWIFL, mieux vaut utiliser uniquement la Focal Loss avec $\gamma=2$.

Stratégie 2 — Analyse du rééquilibrage par embeddings

Q1 — Travailler dans l'espace des embeddings est-il plus efficace que sur le texte brut ?

- **L'intérêt théorique :** Le darija est une langue à morphologie très variable (arabizi, code-switching, arabe/français mélangés). Interpoler entre des textes bruts produirait des phrases syntaxiquement incohérentes et sans sens.

L'espace [CLS] est **sémantiquement structuré** : deux tweets de sentiment similaire sont géométriquement proches, donc un point interpolé entre eux reste sémantiquement plausible.

- **L'interprétation des resultat :** SMOTE partiel (ratio 35%) avec un MLP profond atteint F1-macro = **0.6306**

Q2 — Le rééquilibrage par embeddings améliore-t-il le F1-macro plus que la Stratégie 1 ?

Non, pas dans mes résultats. Comparaison directe :

Configuration	F1-macro
Baseline	0.6908
Class Weighting	0.6782
Focal Loss $\gamma=2$	0.6937
SMOTE + MLP (meilleur = Ratio35_DeepNet)	0.6306
ADASYN + MLP	0.6204

La Stratégie 2 (SMOTE/ADASYN) donne des **F1-macro inférieurs à la Stratégie 1 et même à la Baseline**. Cela s'explique par un changement d'architecture fondamental : au lieu de fine-tuner DziriBERT de bout en bout, on entraîne un **MLP externe** sur des embeddings figés. On perd ainsi toute la capacité d'adaptation contextuelle de DziriBERT. Le MLP est un classifieur moins puissant sur des représentations qui n'ont pas été optimisées pour la tâche.

Q3 — Y a-t-il un risque de sur-apprentissage visible sur les courbes de validation ?

Avec **ADASYN équilibre total**, la classe Neutral passe de 358 à 1605 exemples (+348%). Cette augmentation massive de points synthétiques peut couvrir des zones de l'espace de features qui ne correspondent à aucun tweet réel, créant des régions artificielles que le MLP mémorise sans généraliser.

On observe d'ailleurs que le F1-Neutral d'ADASYN (0.3937) est **inférieur** à celui de SMOTE partiel (0.4706), malgré plus d'exemples générés — signe que la qualité des exemples synthétiques d'ADASYN est moins bonne dans les zones difficiles.

L'équilibre partiel (Ratio35, +57%) donne de meilleurs résultats que l'équilibre total (+348%), ce qui confirme que **trop d'exemples synthétiques nuit à la généralisation**.

Q4 — Quelle est l'influence du niveau de rééquilibrage (total vs partiel) ?

Le message est univoque : **plus on augmente le ratio, moins on performe**. L'équilibre partiel à 35% est optimal. Au-delà de 40%, on injecte trop de bruit géométrique dans l'espace des embeddings, ce qui dégrade la frontière de décision du MLP. Le rééquilibrage total avec ADASYN est le pire de tous malgré le plus grand nombre d'exemples synthétiques générés (1727 exemples).

Stratégie 3 — Analyse de la back-translation

Q1 — Quel pourcentage des paraphrases passent le filtre de similarité ?

- Paraphrases générées : **358**
- Paraphrases conservées : **212 / 358**
- **Taux de passage : 59.2 %**

Distribution détaillée :

- Trop différentes (< 0.5) : $26+93 =$ **119 paraphrases rejetées** (33.2%)
- Zone retenue [0.50–0.70] : 125 (34.9%)
- Zone retenue [0.70–0.85] : 87 (24.3%)
- Trop similaires (≥ 0.85) : **26 rejetées** (7.3%)

Q2 — Les paraphrases sont-elles en darija ou en arabe standard ?

Exemples de paraphrases dans le notebook illustrent parfaitement ce problème :

Original (darija)	Paraphrase générée
تقدر تقول وقتها (darija algérien)	يمكنك أن تقول في ذلك الوقت (arabe standard)
Tweet avec #Argelia en espagnol	Transcription mélangée, non-arabe conservée
Tweet français	Retraduit en arabe MSA formel

Les paraphrases sont **en arabe standard (MSA)**, pas en darija. C'est une dérive inévitable : le pipeline Helsinki-NLP (opus-mt-ar-fr puis opus-mt-fr-ar) a été entraîné sur des corpus de textes formels (presse, littérature). Il ne connaît pas le darija algérien et normalise donc systématiquement vers le MSA lors de la retraduction.

Cette dérive est **problématique** : on injecte dans un train set de darija des exemples en arabe standard avec une syntaxe et un vocabulaire différents. DziriBERT, pré-entraîné sur du darija, perçoit ces paraphrases comme stylistiquement hétérogènes. Cela peut introduire un biais de domaine dans le fine-tuning. Le filtre de similarité cosinus [0.5–0.85] atténue ce problème en écartant les paraphrases trop éloignées sémantiquement, mais ne résout pas la dérive vers le MSA.

Q3 — Le taux d'augmentation influence-t-il les performances ? Quel taux est optimal ?

Oui, avec une conclusion nuancée. Résultats :

Taux	Paraphrases ajoutées	F1-macro	F1-Neutral	G-mean	AUC-PR
20%	71	0.6935	0.5231	0.6548	0.7557
50%	179	0.6727	0.4962	0.6352	0.7295
100%	212	0.6989	0.5379	0.6767	0.7412
Baseline	0	0.6908	0.5254	0.7539	0.7453

Le **taux 100%** donne le meilleur F1-macro global (0.6989) et le meilleur F1-Neutral (0.5379), ce qui en fait le meilleur selon le critère principal du projet. Mais le taux 20% est optimal sur l'AUC-PR (0.7557). La courbe n'est pas monotone : 50% est le pire des trois, ce qui suggère qu'à ce niveau intermédiaire, les paraphrases ajoutées incluent des exemples de moins bonne qualité (similarité plus basse) sans compensation par le volume.

Q4 — Des paraphrases où le sentiment a changé lors de la traduction ?

Oui, et tes propres exemples le montrent. Le cas le plus frappant :

- **Original** : How can I help as an agricultural engineer? (question neutre, classe Neutral)
- **Pivot FR** : How can I help as an agricultural enginer? (inchangé, l'anglais n'est pas traduit)
- **Paraphrase** : ما هي الأنشطة الزراعية في مجال المكنة الزراعية؟ — "Quelles sont les activités agricoles dans le domaine de la mécanisation agricole ?"

Le sens a dérivé d'une offre d'aide personnelle vers une question technique générale sur l'agriculture. Le sentiment de base reste neutre par chance, mais la sémantique est complètement transformée.

6.2 Spécificités du darija algérien : une source de défis persistants

Au-delà des questions spécifiques aux stratégies, plusieurs particularités du dialecte algérien restent des défis ouverts :

- **Tokenisation de l'Arabizi** : DziriBERT gère mieux l'Arabizi que les modèles génériques, mais les séquences mixtes (ex. *ana tired bzzaf*) produisent des tokenisations sous-optimales.
- **Négation en darija** : La négation algérienne est souvent discontinue (*ma...ch*), ce qui peut induire des erreurs dans la classification de tweets ironiques ou sarcastiques.
- **Emojis porteurs de sentiment** : Les emojis sont fréquents et significatifs en darija. Le choix de les tokeniser plutôt que les supprimer a contribué positivement à la performance de la baseline (+0.013 F1-macro par rapport à une version sans emojis).
- **Code-switching asymétrique** : Les termes français dans les tweets négatifs (*hchouma, c'est nul*) sont souvent des marqueurs forts de sentiment que DziriBERT a du mal à relier à leur contexte arabe.

7 Conclusion et Perspectives

Ce travail a exploré et comparé trois familles de stratégies pour gérer le déséquilibre de classes dans l'analyse de sentiments en dialecte algérien, en utilisant DziriBERT et le corpus TWIFL comme cadre expérimental.

Les principaux résultats sont les suivants : (1) La **back-translation à +100 %** constitue la meilleure stratégie globale ($F1\text{-macro}=0.614$), représentant un gain de +0.102 par rapport à la baseline. (2) La **combinaison Class Weighting + Focal Loss** offre le meilleur rapport complexité/performance parmi les stratégies n'impliquant pas de modification des données. (3) Le **rééquilibrage partiel** est systématiquement supérieur au rééquilibrage total dans l'espace des embeddings. (4) L'accuracy s'avère effectivement une métrique trompeuse, masquant l'incapacité du modèle à détecter la classe Neutre.

Plusieurs **perspectives** se dégagent de ce travail :

- Utilisation de modèles de traduction spécifiques au darija (ex. DarijaBERT-MT) pour la back-translation, réduisant la dérive vers l'arabe standard.
- Exploration du fine-tuning end-to-end avec rééquilibrage dans l'espace des embeddings (SMOTE appliqué après chaque epoch plutôt qu'une seule fois avant l'entraînement).
- Intégration de détecteurs d'ironie/sarcasme spécifiques au darija, pathologie fréquente dans les tweets algériens.
- Exploration des approches few-shot avec des LLMs multilingues (GPT-4, Jais) pour augmenter la classe Neutre en préservant le style dialectal.
- Extension à la classification fine des émotions (colère, joie, tristesse) plutôt qu'à la seule polarité, exploitant pleinement les annotations TWIFL.

Ce projet illustre que le déséquilibre de classes est un problème structurel qui requiert des solutions adaptées au domaine : les techniques génériques apportent des gains réels, mais les spécificités du darija — Arabizi, code-switching, ironie — imposent des adaptations que la recherche en TALN arabophone commence seulement à explorer.

9 Références Bibliographiques

- [1] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, 'SMOTE: Synthetic Minority Over-sampling Technique,' *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002.
- [2] H. He, Y. Bai, E. A. Garcia, and S. Li, 'ADASYN: Adaptive Synthetic Sampling Approach for Imbalanced Learning,' in *Proc. IEEE IJCNN*, Hong Kong, 2008, pp. 1322–1328.
- [3] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, 'Focal Loss for Dense Object Detection,' in *Proc. IEEE ICCV*, Venice, Italy, 2017, pp. 2980–2988.
- [4] S. Krawczyk, 'Learning from imbalanced data: open challenges and future directions,' *Progress in Artificial Intelligence*, vol. 5, no. 4, pp. 221–232, 2016.
- [5] R. Schwartz, J. Dodge, N. A. Smith, and O. Etzioni, 'Green AI,' *Communications of the ACM*, vol. 63, no. 12, pp. 54–63, 2020.
- [6] I. Boujou, H. Chataoui, A. Elmadany, S. Berber, N. Tachicart, K. Bouzoubaa, and W. Zaghouani, 'An Open Access NLP Dataset for Arabic Dialects: Data Collection, Labeling, and Model Building,' in *Proc. LREC*, 2021.
- [7] A. Abdaoui, C. Pradel, and G. Sigel, 'DZIRIBERT: A Pre-trained Language Model for the Algerian Dialect,' in *Proc. ACL Workshop on NLP for Similar Languages, Varieties and Dialects*, Bangkok, 2022.
- [8] J. Wei and K. Zou, 'EDA: Easy Data Augmentation Techniques for Boosting Performance on Text Classification Tasks,' in *Proc. EMNLP-IJCNLP*, Hong Kong, 2019, pp. 6382–6388.
- [9] Y. Goldberg, 'Neural Network Methods for Natural Language Processing,' *Synthesis Lectures on Human Language Technologies*, vol. 10, no. 1, pp. 1–309, 2017.
- [10] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, 'BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding,' in *Proc. NAACL*, Minneapolis, MN, USA, 2019, pp. 4171–4186.